

Bengali LLM Hallucination Detection Challenge

Team: **Bitwiz**

Phase1 Score = 0.934 | Phase2 Score = 0.92111

Hallucination Detection

Task Definition

For a given context and prompt, detect if its hallucinated or not:

- **Label 0** – Response is hallucinated
- **Label 1** – Response is not hallucinated

Evaluation Metric

Macro F1 Score on Label 0

Key Challenges

1. Different Verification Regimes

One binary label combines numerical checking, Bengali language, external factuality, and passage entailment.

2. Bengali Language & Tokenization

Subword fragmentation, Unicode/spelling variation, and lexical ambiguity weaken matching and consume more prompt tokens.

3. Evidence Localization & Conflict

A direct answer can be buried in a long context, while retrieved evidence may be incomplete, irrelevant, or about the wrong entity.

4. Offline Compute Constraint

A 35B verifier and live retrieval must process roughly 5,000 rows on two T4 GPUs within Kaggle's nine-hour limit.

The Core Idea

“Hallucination” is four different tasks wearing one label.

Math

Wrong because the *arithmetic* is wrong.

Needs verification, not evidence.

Grammar / Lexical

Wrong because the *word meaning* is wrong.

Needs a dictionary, not reasoning.

No-Context GK

Wrong because the *world* says otherwise.

Needs external evidence.

Context-Grounded

Wrong because the *passage* says otherwise.

Needs entailment, passage only.

Key Takeaway

Raw Model Inference Comparison

Direct model pass on the same 2,516 rows


Base model	Form	Raw macro-F1	Inference time
Qwen3-4B-Instruct	Standard	0.6900	1 h 52 m
Qwen3-14B-Instruct	Standard	0.7110	2 h 48 m
Qwen3-30B-A3B	GPTQ-Int4	0.7900	4 h 00 m
Qwen3.5-35B-A3B	GPTQ-Int4	0.8224	2 h 18 m
Qwen3.6-35B-A3B	GPTQ-Int4	0.8110	2 h 10 m

Timing Scope

Raw inference only for 2,516 rows – not end-to-end runtime. Times exclude domain routing, lexical archive lookup, selective RAG, reranking, preprocessing, and submission assembly.

Qwen3.5-35B-A3B gave the strongest raw F1 while remaining practical on two Tesla T4 GPUs.

High-Level Architecture Overview



Key Innovation


Detection modules provide contextual hints that compensate for the core model's weaknesses.

Multiple curated sources – all mountable offline.

Knowledge family	Representative sources	Raw size	Prepared / indexed
Grammar, orthography & lexicon	grammar, dictionaries, synonyms/antonyms, idioms	syn- ~1.5 GB	1,885,740 chunks
Law, administration & civic services	bdlaws, Constitution, service rules, Citizen Charter	~127 MB	190,558 ch. + 45,321 rows
Curriculum, literature & commerce	NCTB 6–12, SSC/ICT, biographies, <i>Lal-salu</i> , accounting	≥9 MB	31,762 ch. + 5,317 rows
GK, MCQ & culture	BCS/admission, current affairs, Bangla MMLU, cultural QA	~37 MB	7,385 ch. + 56,903 rows
Medical & bilingual QA	BanglaMMedBench, BanglaMedQA, bilingual medical facts	~6 MB	9,413 rows
News & transcripts	Prothom Alo pipeline, 13 Saon transcripts	not consolidated	prepared; not in final v4
Recorded total	22 source types; overlapping stage counts		≥2.23M units

Offline Knowledge Base Ingestion

OFFLINE KB INGESTION



Chunking Strategy

Problem

- **Retrieval Match:** Can't retrieve if chunks do not contain broader information.
- **Too Big Chunk:** Can't make the chunk too big as it will bloat context

Solution

Attach **concise, relevant metadata** to every chunk before indexing

Example 1

[গণপ্রজাতন্ত্রী বাংলাদেশের সংবিধান (১৯৭২)]
[২ক -- রাষ্ট্রধর্ম] প্রজাতন্ত্রের রাষ্ট্রধর্ম ইসলাম, তবে
হিন্দু, বৌদ্ধ, খ্রীষ্টানসহ অন্যান্য ধর্ম পালনে রাষ্ট্র
সমমর্যাদা ও সমঅধিকার নিশ্চিত করিবে।

Example 2

[বাংলা ব্যাকরণ -- সমাসের প্রকারভেদ] [অর্থের
প্রাধান্য] ব্যাসবাক্য নির্মাণের ভিত্তিতে বিচার করলে
দেখা যায়, পদগুলোতে কখনো পূর্বপদের, কখনো
পরপদের আর কখনো উভয়পদের অর্থ প্রাধান্য
লাভ করে।

Normalization & Dedup

Fuzzy dedup at threshold 97 removed near-duplicate chunks – and freed up the top-3.

Normalize

NFC, unify quotes, Bengali→ASCII digits, collapse whitespace.

Same pipeline at index time *and* query time

Dedup Benefit

Dedup brings diversity in the 3-slot RAG budget.

Top-3 Before Dedup

- | | |
|---|------|
| 1. বাংলাপিডিয়া -- "কৃষ্ণ" নিবন্ধ, অনুচ্ছেদ ১ | 0.91 |
| 2. বাংলাপিডিয়া -- কৃষ্ণ" নিবন্ধ, অনুচ্ছেদ ১ (কপি) | 0.90 |
| 3. বাংলাপিডিয়া -- "কৃষ্ণ" নিবন্ধ, অনুচ্ছেদ ১ (কপি) | 0.90 |


Unique sources: 1

Top-3 After Dedup

- | | |
|--|------|
| 1. বাংলাপিডিয়া -- "কৃষ্ণ" নিবন্ধ | 0.91 |
| 2. কৃষ্ণের সর্বাধিক প্রচলিত নামদুটি হল গোবিন্দ (গো-অশ্বেষক) ও গোপাল (গো-রক্ষাকারী) | 0.84 |
| 3. আদি শঙ্করের মতে আনন্দের অস্তিত্ব।[11] কৃষ্ণের একাধিক নাম ও অভিধা রয়েছে। | 0.79 |

Unique sources: 3


Hybrid Retrieval & Reranking



Retrieval: Sparse + Dense, fused at $\alpha_{\text{dense}} = 0.7$

Reranking: cross-encoder rerank → discard below **0.75** →

keep top 3



F1 vs α_{dense}

The Four Experts

Each expert encodes a different notion of “wrong”.

1. Math

Checks: Final numeric answer

Mechanic: Forced re-derivation + verification identities

Evidence: None (RAG skipped)

2. Grammar / Lexical

Checks: Word & idiom meaning

Mechanic: Exact-term discipline, no paraphrase credit

Evidence: Archive + multi-query RAG

3. No-Context GK

Checks: External factuality

Mechanic: Evidence-or-abstain framing

Evidence: Hybrid RAG top-3

4. Context-Grounded

Checks: Entailment vs. passage

Mechanic: Passage-only, ignore world knowledge

Evidence: The row's own context

One Example per Expert

Row → baseline's wrong call → expert's right call.

Math

Test ID 301: বুধবার + ৫১ দিন; উত্তর: বৃহস্পতিবার

× **Baseline:** gets $51 \bmod 7 = 2$, but miscounts Wed+2; predicts **1**

✓ **Expert:** Wed+2 = Friday; response is wrong → **0**

Why: final-value re-derivation catches the off-by-one error.

No-Context GK

Test ID 54: পদ্মা--মেঘনা কোথায় মেলে? উত্তর: গোয়ালন্দ

× **Baseline:** calls Goalanda a “well-known fact” → **1**

✓ **Expert:** top evidence says Chandpur; mismatch → **0**

Why: grounded retrieval corrects confident false recall.

Grammar / Lexical

Test ID 2307: প্রখর-এর বিপরীত? উত্তর: স্নান

× **Baseline:** retrieves synonyms তীক্ষ্ণ/তীব্র; rejects it → **0**

✓ **Expert:** detects antonym intent; accepts স্নান → **1**

Why: relation gating prevents synonym contamination.

Context-Grounded (most interesting)

Test ID 1167: Context: পিতা রামলোচন; answer: গোপীমোহন

× **Baseline:** overrides the explicit passage with memory → **1**

✓ **Expert:** direct context contradiction → **0**

Why: direct passage evidence outranks model memory.

One Hard Row, End to End (1/3)

1 – Input Row

Context: হোসেন শহীদ সোহরাওয়ার্দী ও আবুল হাশেমের নেতৃত্বাধীন তৎকালীন বঙ্গীয় প্রাদেশিক মুসলিম লীগের একাংশের সম্মেলনের মধ্য দিয়ে ১৯৪৯ সালের ২৩ জুন ঢাকার টিকাটুলীর কেএম দাস লেন রোডের রোজ গার্ডেন প্যালেসে 'পূর্ব পাকিস্তান আওয়ামী মুসলিম লীগ' প্রতিষ্ঠিত হয়, যার সভাপতি ছিলেন টাঙ্গাইলের মওলানা আবদুল হামিদ খান ভাসানী এবং সাধারণ সম্পাদক টাঙ্গাইলের শামসুল হক। পরবর্তীকালে ১৯৫৫ সালে মওলানা ভাসানীর উদ্যোগে সংগঠনটির নাম থেকে 'মুসলিম' শব্দটি বাদ দিয়ে নাম রাখা হয় 'পূর্ব পাকিস্তান আওয়ামী লীগ'।

Prompt: বাংলাদেশ আওয়ামী লীগের প্রতিষ্ঠাতা কে ছিলেন?

Response: শেখ মুজিবুর রহমান ও মওলানা ভাসানী ছিলেন।

2 – Baseline (Single Generic Prompt)

Output: **Not Hallucinated** FINAL_LABEL=1 × **wrong**

One Hard Row, End to End (2/3)

3 – Router Decision

Context is present (not null) → bucket context_grounded

4 – Retrieved & Reranked Chunks

- | | |
|---|------|
| 1. বাংলাদেশী ব্যক্তিবর্গ -- হামিদ খান ভাসানী, আওয়ামী লীগের প্রতিষ্ঠাতা | 1.00 |
| 2. বাংলাদেশ আওয়ামী লীগ -- প্রতিষ্ঠা: সোহরাওয়ার্দী ও আবুল হাশিম, ১৯৪৯ | 0.99 |
| 3. আবদুর রশীদ তর্কবাগীশ -- আওয়ামী লীগের অন্যতম প্রতিষ্ঠাতা | 0.99 |

All three chunks name Suhrawardy, Abul Hashim, Bhashani, and Tarkabagish as founders – none mention Sheikh Mujibur Rahman.

5 – Prompt Assembled

6 – Model Reasoning

Context এবং Evidence উভয়েই স্পষ্টভাবে বলছে যে ১৯৪৯ সালে হোসেন শহীদ সোহরাওয়ার্দী ও আবুল হাশেমের নেতৃত্বে, এবং মওলানা ভাসানীকে সভাপতি করে দলটি প্রতিষ্ঠিত হয়। মওলানা ভাসানীর নাম সঠিক, কিন্তু Response- এ উল্লিখিত "শেখ মুজিবুর রহমান" কোথাও প্রতিষ্ঠাতা হিসেবে উল্লেখ নেই -- তিনি পরবর্তীতে দলের নেতৃত্বে আসেন, প্রতিষ্ঠাতা ছিলেন না। তাই Response আংশিক সঠিক হলেও একটি ভুল তথ্য যুক্ত করেছে, ফলে এটি Hallucinated FINAL-LABEL=0,

FINAL_LABEL=0 ✓ correct (hallucinated)

Specific Problems

Two edge cases the pipeline had to handle explicitly.

Problem 1 – Reasoning Without a Label

Model reasons correctly but sometimes stops *before* emitting FINAL_LABEL – row is left unlabeled.

Ex. (*repetition loop, no label*): গৌতম চট্টোপাধ্যায় কলকাতায় গৌতম চট্টোপাধ্যায় কলকাতায় ...

Fix: detect unlabeled rows → re-infer using the model's own reasoning trace as context to force a final label.

Problem 2 – Retrieval Needs the Response, Too

Query alone retrieves the wrong evidence for some question types – the *response* is needed to know what to look up.

Ex. (*antonym row*): জাগ্রত শব্দের শুদ্ধ বিপরীত শব্দ কোনটি? → নিদ্রিত

Fix: classify these rows → retrieve using **query + response** together.

- **Weakest Performance on Label 1 (Non-Hallucinated).**

The system is more conservative and tends to predict hallucination in ambiguous cases, making Label 1 harder to identify correctly. Future work includes confidence calibration and improved reasoning prompts.

- **Limited Retrieval Coverage.**

The RAG knowledge base is built primarily from Bengali newspaper articles. Questions requiring religious, historical, or other domain-specific knowledge may lack sufficient evidence. Expanding the corpus with diverse, high-quality sources is a key direction for future work.